

Transcripción Automática de Audio en Idioma Kichwa mediante Deep Learning

PROBLEMA



El **Kichwa** es una **lengua de bajos recursos computacionales**, con escasa disponibilidad de datos de voz etiquetados para desarrollar sistemas de reconocimiento automático del habla.


Su **variabilidad lingüística** (morfología aglutinante, diferentes hablantes, pronunciación y code-switching) incrementa la complejidad de generar transcripciones automáticas precisas



OBJETIVO GENERAL




Transcribir audio en **idioma Kichwa** mediante un **modelo de reconocimiento automático de voz**



SOLUCIÓN

Se implementó un sistema ASR que combina un **extractor Wav2Vec2 reconstruido** explícitamente (con 6 capas Transformer) y un **decodificador convolucional 1D propio**, entrenado sobre el corpus KillKan mediante CTC Loss.


- Wav2Vec2 reconstruido** se usa sólo pesos preentrenados
- Encoder reducido a 6 capas Transformer** para disminuir costo computacional
- Representaciones** acústicas (embeddings) de 768 dimensiones
- Decodificador Conv1D** con convoluciones dilatadas, entrenado para caracteres de Kichwa
- Entrenamiento con **CTC Loss** y decodificación greedy



RESULTADOS


- El modelo muestra convergencia durante el entrenamiento y aprende patrones acústicos del Kichwa.
- Se observa una reducción significativa del Character Error Rate (CER), aunque el Word Error Rate (WER) sigue siendo elevado debido a la limitada cantidad de datos.

Pérdida de entrenamiento y validación



La pérdida disminuye progresivamente, evidenciando aprendizaje y convergencia del modelo

CER Y WER en el conjunto de prueba



El CER mejora considerablemente, pero el WER sigue alto, lo que indica dificultad para reconocer palabras completas

CONCLUSIONES



El sistema demuestra viabilidad de construir un modelo ASR para Kichwa utilizando representaciones preentrenadas y un decodificador especializado



El modelo aprende patrones relevantes del idioma, evidenciado por la disminución de la pérdida y del CER durante el entrenamiento



La principal limitación es la cantidad limitada de datos (aprox. 4 horas), lo que impacta el desempeño a nivel de palabras (WER). Se requiere recopilar más pdatos para alcanzar transcripciones robustas en escenarios reales

NUESTRA CONTRIBUCIÓN

- Reconstrucción explícita de un extractor Wav2Vec parcial.
- Reducción del encoder contextual a 6 capas Transformer.
- Diseño e implementación de un decodificador Conv1D con convoluciones dilatadas.
- Entrenamiento especializado para caracteres del Kichwa mediante CTC Loss